# Veldig praktisk dataanalyse

**En innføring i bruk av R**

Torbjørn Skardhamar

2023-12-29

# Table of contents

**Forord** **3**
Hvordan bli god? . . . 3
Datasett . . . 4
Til studenter . . . 4
Til undervisere . . . 4

**1 Lese inn datasett** **5**
1.1 Generelt om ulike dataformat . . . 5
1.2 Lese inn datasett og få oversikt . . . 5
1.2.1 Undersøke enkeltvariable med `codebook()` fra pakken {memisc} . . . 8

**2 Grafikk med ggplot** **10**
2.1 Lagvis grafikk . . . 10
2.2 Stolpediagram . . . 11
2.3 Stolpediagram med flere variable . . . 15
2.3.1 Kakediagram . . . 17
2.4 Grafikk for kontinuerlige data . . . 20
2.4.1 Histogram . . . 20
2.4.2 Density plot . . . 23
2.4.3 Flere variable samtidig . . . 28

# Forord

Denne boken er beregnet som en veldig praktisk innføring i dataanalyse med R. Med det som gjennomgås i denne boken skal du være i stand til å skrive en enkel rapport, med deskriptive tabeller og figur, og grunnleggende regresjonsanalyse.

Dette er imidlertid ikke en lærebok i statistikk og metode, så det vil ikke vektlegges dypere forklaringer av statistiske begreper, fordelinger, designvalg osv. Du bør konsultere en annen standard lærebok for slike ting. Men all statistikk gjøres i praksis med datamaskiner og programmering. Denne boken vektlegger denne praktiske siden.

R er et programmeringsspråk spesielt godt egnet for statistisk analyse og databehandling, og det er viktig å lære å skrive kode både for databehandling og analyse. Men boken er *ikke* ment som en innføring i programmering, og målsettingen er ikke at du skal beherske R-programmering som sådan. Det overordnede fokuset er å få gjort analyser raskt og effektivt.

Dette er en bok som lærer deg hvordan få ting gjort med R. Fra import av data til output av publiserbar kvalitet. Det vektlegges arbeidsflyt, mappestruktur og stilistiske elementer. Dette er for å lette arbeidet ditt, gjøre koden lettere å lese og generelt holde orden.

Boken vektlegger også det estetiske. Alle tabeller og figurer skal være *pene* i den forstand at de skal være informative, lette å lese, og bruke en layout som er tiltalende. Dessuten skal alt kunne eksporteres til vanlige tekstbehandlingsprogram. Klipp-og-lim skal være unødvendig.

Et moment ved det estetiske er fargebruk. I tillegg til at R støtter avansert fargebruk er det også enkle fargepaletter tilgjengelig. Men det er viktig at fargebruken er funksjonell så alle kan lese det. Derfor må fargevalg ta hensyn til slike ting som fargeblindhet. Slikt dekkes også.

## Hvordan bli god?

Analyse av data er praktiske ferdigheter og for å bli god må du øve. Hvert kapittel inneholder derfor en rekke oppgaver som du må jobbe med. Teksten har mange eksempler med bruk av ett eller flere datasett, og så skal du gjøre tilsvarende med andre datasett. Bruk gjerne helt andre datasett også, og jobb praktisk med oppgaver.

## Datasett

De aller fleste datasettene som brukes i denne boken finnes tilgjengelig i diverse R-pakker, og det er referanser til disse gjennomgående slik at du lett kan finne dem. I tillegg er datasettene gjort tilgjengelig på bokens ressursside. Noen datasett som brukes er hentet fra andre kilder, som for eksempel offisiell statistikk fra SSB, eller utdrag fra andre datasett som ikke nødvendigvis er åpent tilgjengelig ellers.

For en oversikt over andre datasett lett tilgjengelig i R, se hjemmesiden til Vincent Arel-Bundock som inneholder en oversikt.

## Til studenter

For all kvantitativ analyse er det svært viktig at man jobber med kode. Når du har gjort alt arbeidet med kode kan du enkelt gjøre analysen på nytt med samme data eller nye data. Koden er langt på vei dokumentasjon på den jobben du gjør, og gjør analysene dine reproduserbare. Å lære seg dataanalyse med meny-baserte verktøy er derfor ikke et alternativ for seriøse analyser. Vitenskapen skal være reproduserbar, og da må det skrives kode.

Dette betyr ikke at du behøver være spesielt interessert i datamaskiner eller informatikk. Å kunne kode har visse nerde-assosisasjoner, men ikke la deg affisere av det. Her er det det praktiske som vektlegges og du skal lære så lite programmering som mulig - men nok til å gå gjort det du skal. Du trenger forsåvidt en god del, så det blir mye kode som skal skrives.

Hvis du er av den typen som gjerne skulle vært litt mer nerdete så er du kanskje mer bekymret for at det blir for lite kode? Dette er uansett et godt sted å starte. Denne boken er lagt opp som en innføring på relativt lavt nivå, men utøver konsekvent prinsipper du trenger på et høyere nivå. Alt i denne boken kan påbygges til avansert programmering.

## Til undervisere

Denne boken har gjort en del strategiske valg av pakker og funksjoner som brukes gjennomgående. Først og fremst brukes *tidyverse* gjennomgående, og andre funksjoner som brukes vil være kompatible med tidyverse. Dette gir en konsistent og effektiv kode gjennomgående.

Det vektlegges gjennomgående at alle resultater skal bli pene, i publiserbar kvalitet, og i en form som lar seg eksportere til tekstbehandlingsprogram i MS Office, fordi det i praksis er dette de fleste bruker. Men det er også vektlagt å bruke eksportfunksjoner som *også* kan eksportere til andre formater som pdf, html or rft, og er kompatible med Markdown/Quarto. Selv om de fleste nybegynnere i R ikke jobber i disse formatene skal de ikke behøve å bytte funksjoner hvis de skulle ha behov for det senere.

# 1 Lese inn datasett

I dette kapittelet skal vi bruke følgende pakker:

```
library(tidyverse)
library(memisc)
```

## 1.1 Generelt om ulike dataformat

Data kan være lagret i mange ulike formater, og du vil kunne få data i et format som ikke er tilrettelagt verken i eller for R. Å gjøre om data fra et format til et annet kan være en avgjørende oppgave for å få gjort noe som helst. R kan imidlertid håndtere det aller meste av dataformater på en eller annen måte. Foreløpig skal vi kun se på et dataformat som er spesielt egnet for R, nemlig rds-formatet. Alle datasett som følger med denne boken vil være i rds-formatet, med unntak av kapittelet der temaet er import av andre formater.

## 1.2 Lese inn datasett og få oversikt

Vi bruker her et lite utvalg variable fra Ungdata 2010-2020 (NOVA and Bakken (2023)) som er lagret i rds-format. Dette datasettet er tilgjengelig på NSD sine sider. Følgende kode bruker funksjonen `readRDS` for å lese inn datasettet. Filbanen er angitt å ligge i en mappe som heter "data" i prosjektmappen, og filnavnet er "ungdata_alko.rds". Når man leser inn dataene legges de i et "objekt" som vi her kaller *ungdata_alko*.

```
ungdata_alko <- readRDS("data/ungdata_alko.rds")
```

En første ting man bør sjekke er om dataene er lest inn riktig og at det rett og slett ser greit ut. Det er lite som kan gå galt når man leser inn en rds-fil, men det kan være en fordel for deg selv å se på dataene og se hvordan de ser ut. Vi kan se på objektet *ungdata_alko* ved å skrive navnet på objektet i konsollen. Da vil R i utgangspunktet skrive *hele* datasettet i konsollen.

```
ungdata_alko
```

```
# A tibble: 845,100 x 5
   klasse    ar    kjonn  alko1                              drikker
   <fct>     <fct> <fct>  <fct>                                <dbl>
 1 9. trinn 2014  Gutter Aldri                                    0
 2 9. trinn 2014  Gutter Aldri                                    0
 3 8. trinn 2014  Gutter Aldri                                    0
 4 9. trinn 2014  Gutter Aldri                                    0
 5 8. trinn 2014  Gutter Aldri                                    0
 6 9. trinn 2014  Jenter Aldri                                    0
 7 8. trinn 2014  Gutter Aldri                                    0
 8 8. trinn 2014  Gutter Har bare smakt noen få ganger            1
 9 8. trinn 2014  Jenter Aldri                                    0
10 9. trinn 2014  Jenter Har bare smakt noen få ganger            1
# i 845,090 more rows
```

Det er imidlertid sjelden hensiktsmessig å se på hele datasettet på denne måten. Det er for det første ikke plass til å vise hele datasettet i konsollen, og for det andre er det ikke så lett å få oversikt over datasettet på denne måten. Hvis du virkelig vil se på hele datasettet er det bedre å bruke `View`-funksjonen som åpner datasettet i et eget vindu.

```
View(ungdata_alko)
```

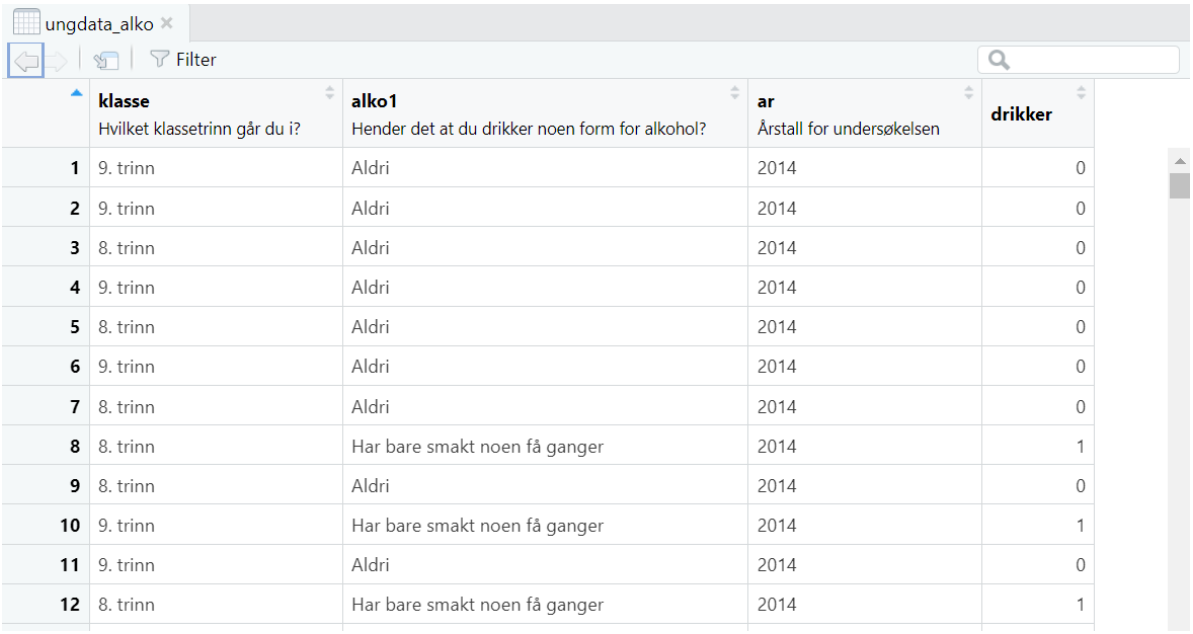


| | klasse<br>Hvilket klassetrinn går du i? | alko1<br>Hender det at du drikker noen form for alkohol? | ar<br>Årstall for undersøkelsen | drikker |
|---|---|---|---|---|
| 1 | 9. trinn | Aldri | 2014 | 0 |
| 2 | 9. trinn | Aldri | 2014 | 0 |
| 3 | 8. trinn | Aldri | 2014 | 0 |
| 4 | 9. trinn | Aldri | 2014 | 0 |
| 5 | 8. trinn | Aldri | 2014 | 0 |
| 6 | 9. trinn | Aldri | 2014 | 0 |
| 7 | 8. trinn | Aldri | 2014 | 0 |
| 8 | 8. trinn | Har bare smakt noen få ganger | 2014 | 1 |
| 9 | 8. trinn | Aldri | 2014 | 0 |
| 10 | 9. trinn | Har bare smakt noen få ganger | 2014 | 1 |
| 11 | 9. trinn | Aldri | 2014 | 0 |
| 12 | 8. trinn | Har bare smakt noen få ganger | 2014 | 1 |

Du kan lukke dette vinduet med dataene uten at det har noe å si for dataene, som fremdeles er tilgjengelig i objektet på samme måte som før.

Det er vanligvis ikke så nyttig å se på datasettet på denne måten heller. Det er derfor vanligvis mer hensiktsmessig å se på en del av datasettet med å bare be om å få se de første observasjonene. Da får du et innblikk i datastrukturen, variable og verdier. Dette gjøres med funksjonen `head`.

```
head(ungdata_alko)
```

```
# A tibble: 6 x 5
  klasse   ar    kjonn  alko1 drikker
  <fct>    <fct> <fct>  <fct>   <dbl>
1 9. trinn 2014  Gutter Aldri       0
2 9. trinn 2014  Gutter Aldri       0
3 8. trinn 2014  Gutter Aldri       0
4 9. trinn 2014  Gutter Aldri       0
5 8. trinn 2014  Gutter Aldri       0
6 9. trinn 2014  Jenter Aldri       0
```

Hvis det er mange variable i datasettet vil det ikke bli plass i consoll-vinduet til å vise alle variablene. Da vil R bare vise de første variablene og skrive at det er flere variable som ikke vises. Da kan det være mer hensiktsmessig å bruke funksjonen `glimpse` som viser variabelnavnene i rader, med de tilhørende første verdiene.

```
glimpse(ungdata_alko)
```

```
Rows: 845,100
Columns: 5
$ klasse  <fct> 9. trinn, 9. trinn, 8. trinn, 9. trinn, 8. trinn, 9. trinn, 8.~
$ ar      <fct> 2014, 2014, 2014, 2014, 2014, 2014, 2014, 2014, 2014, 2014, 20~
$ kjonn   <fct> Gutter, Gutter, Gutter, Gutter, Gutter, Jenter, Gutter, Gutter~
$ alko1   <fct> "Aldri", "Aldri", "Aldri", "Aldri", "Aldri", "Aldri", "Aldri",~
$ drikker <dbl> 0, 0, 0, 0, 0, 0, 0, 1, 0, 1, 0, 1, 0, 1, 0, 0, 1, 1, 1, 1, 0,~
```

`glimpse` gir også noe ytterligere informasjon, som antall observasjoner i datasettet og og hvilken type variablene er. Når det i output står "dbl" betyr at det er en numerisk variabel, og "fct" betyr at det er en faktorvariabel.

Det finnes også andre variabeltyper enn det som er i eksempelet, herunder betyr "chr" at det er en tekstvariabel, "int" betyr at det er en heltallsvariabel, "date" betyr at det er en dato-variabel, og "lgl" betyr at det er en logisk variabel (dvs. en variabel som kan ha verdiene TRUE eller FALSE). Vi kommer tilbake til disse variabeltypene etterhvert.

Funksjonen `class()` gir informasjon om hva slags objekt man har. Her sjekkes objektet *ungdata_alko*:

```
class(ungdata_alko)
```

```
[1] "tbl_df"     "tbl"        "data.frame"
```

I dette tilfellet får vi tre beskjeder. Det er en kombinert objekttype av *tibble* og *data.frame*. Mens *data.frame* er standard datasett tilsvarende som et regneark, så er *tibble* en utvidelse med noen ekstra funksjoner som er nyttige for avanserte brukere, men er å regne som en utvidelse av *data.frame*. For vårt formål vil det i praksis være det samme. Et datasett som leses inn i R bør altså være av typen tbl eller data.frame. Data kan også ha andre typer strukturer og da vil `class()` rapportere noe annet.

Når man bruker funksjoner i R, så vil noen ganger resultatet avhenge av hva slags type objekt det er.

For å vite hvor mange rader og kolonner det er i datasettet kan man bruke funksjonen `dim()` slik:

```
dim(ungdata_alko)
```

```
[1] 845100      5
```

Her får vi vite at det er 845100 rader (dvs. observasjoner) og 5 kollonner (dvs. variable).

### 1.2.1 Undersøke enkeltvariable med `codebook()` fra pakken {memisc}

Noen ganger vil man ha litt mer informasjon om enkeltvariablene. Noen datasett vil komme med labler (omtalt annet sted) eller faktorvariable, som gjør at variablene inneholder både tallverdier og tekst.

Å få ut noe deskriptiv statistikk og se på fordelinger er da gjerne neste steg som vil bli behandlet i de etterfølgende kapitlene.

Pakken {memisc} inneholder en rekke funksjoner for å håndtere surveydata, som vi ikke skal gå nærmere inn på her. Men akkurat funksjonen `codebook()` gir litt mer informativt output.

```
library(memisc)
codebook(ungdata_alko$alko1)
```

```
================================================================================

   ungdata_alko$alko1 'Hender det at du drikker noen form for alkohol?'

--------------------------------------------------------------------------------

   Storage mode: integer
   Factor with 5 levels

   Levels and labels                                    N  Valid

   1 'Aldri'                                       374957   44.4
   2 'Har bare smakt noen få ganger'               174322   20.6
   3 'Av og til, men ikke så ofte som månedlig'    145934   17.3
   4 'Nokså jevnt 1-3 ganger i måneden'            112311   13.3
   5 'Hver uke'                                     37576    4.4
```

Grunnen til å bruke `codebook` er å få et raskt innblikk i enkeltvariable, inkludert fordelingen av verdier. Dette er mest informativt for kategoriske variable eller numeriske variable med relativt få verdier.

# 2 Grafikk med ggplot

I dette kapittelet skal vi bruke følgende pakker:

```
library(tidyverse)
library(ggforce)
library(ggthemes)
library(datasets)
```

I R er det flere systemer for grafikk. Noen er spesialiserte og knyttet til spesielle analysemetoder og gir deg et spesifikt output slik at funksjonen `plot()` gir deg akkurat det du skal ha. Det er forsåvidt veldig praktisk, men er ikke gode nok til å bli med i en rapport.

Vi skal her vektlegge et *generelt system* for grafikk som finnes i pakken {ggplot2} som er en del av tidyverse. Funksjonen `ggplot` kan brukes til all slags grafikk, fra helt grunnleggende til avansert, professjonell grafikk. Funksjonen `ggplot` er bygget opp som en *gramatikk* for grafisk fremstilling. Det ligger altså en teori til grunn som er utledet i boken ved omtrent samme navn: The grammar of graphics. Det er mye som kan sies om dette, men det viktige er at grafikken er bygget opp rundt noen bestanddeler. Når du behersker disse kan du fremstille nær sagt hva som helst av kvantitativ informasjon grafisk. Dette er altså et system for grafikk, ikke bare kommandoer for spesifikke typer plot. Vi skal likevel bare dekke de mest grunnleggende typer plot her.

## 2.1 Lagvis grafikk

Systemet er bygd opp *lagvis*. Det gjelder selve koden, men også hvordan det ser ut visuelt. Man kan utvide plottet med flere lag i samme plot og det legges da oppå hverandre i den rekkefølgen som angis i koden.

For enkle plot som vi skal bruke her angir man i denne rekkefølgen og med en `+` mellom hver del (vanligvis per linje, men linjeskift spiller ingen rolle). Hver del av koden spesifiserer enten *hva* som skal plottes eller *hvordan* det plottes, mens andre deler kan kontrollere utseende på akser, fargeskalaer, støttelinjer eller andre ting som har med layout å gjøre.

1) Angi data og *hva* som skal plottes med `ggplot()`
2) Angi *hvordan* det skal plottes med `geom_*()`
3) Angi andre spesifikasjoner (farger, titler, koordinatsystemer osv)

Dette blir tydeligere i eksemplene og forklares underveis.

- Det første argumentet i `ggplot` er data. Altså: hvilket datasett informasjonen hentes fra.
- Inni `ggplot()` må det spesifiseres `aes()`, "*aestethics*", som er *hvilke variable* som skal plottes. Først og fremst hva som skal på x-akse og y-akse (og evt. z-akse), men også spesifikasjon av om linjer (farge, linjetype) og fyllfarger, skal angis etter en annen variabel.
- `geom_*` står for *geometric* og sier noe om *hvordan* data skal se ut. Det kan være punkter, histogram, stolper, linjer osv.
- `coord_*` definerer koordinatsystemet. Stort sett blir dette bestemt av variablene. Men du kan også snu grafen eller definere sirkulært koordinatsystem, eller andre enklere ting.
- `facet_*` definerer hvordan du vil dele opp grafikken i undergrupper

## 2.2 Stolpediagram

Eksempeldataene her er fra Ungdata 2010-20202, og vi skal se på selvrapportert bruk av alkohol. Variabelen *alko1* er for spørsmålet om hvor ofte intervjupersonenene drikker alkohol, og det er en kategorisk variabel med 5 kategorier: Aldri, sjelden, av og til, ofte og veldig ofte.

Vi lager et plot med funksjonen `ggplot` med koden nednefor. Første linje spesifiserer hva som skal plottes. Her er det første argumentet datasettet som skal brukes, og det andre er `aes()` som står for *aestethics* og er en funksjon som spesifiserer hvilke variable som skal brukes. Her er det bare en variabel som skal plottes, og det er *alko1* som plasseres langs x-aksen. Det andre argumentet er `geom_bar` som spesifiserer at det skal være stolpediagram. Når man skriver kun `geom_bar` er en forkortelse for `geom_bar(stat = "count")` som betyr at det skal være en stolpe for hver kategori og høyden på stolpen skal være antall observasjoner i hver kategori.

```
ggplot(ungdata_alko, aes(x = alko1)) +
  geom_bar()
```

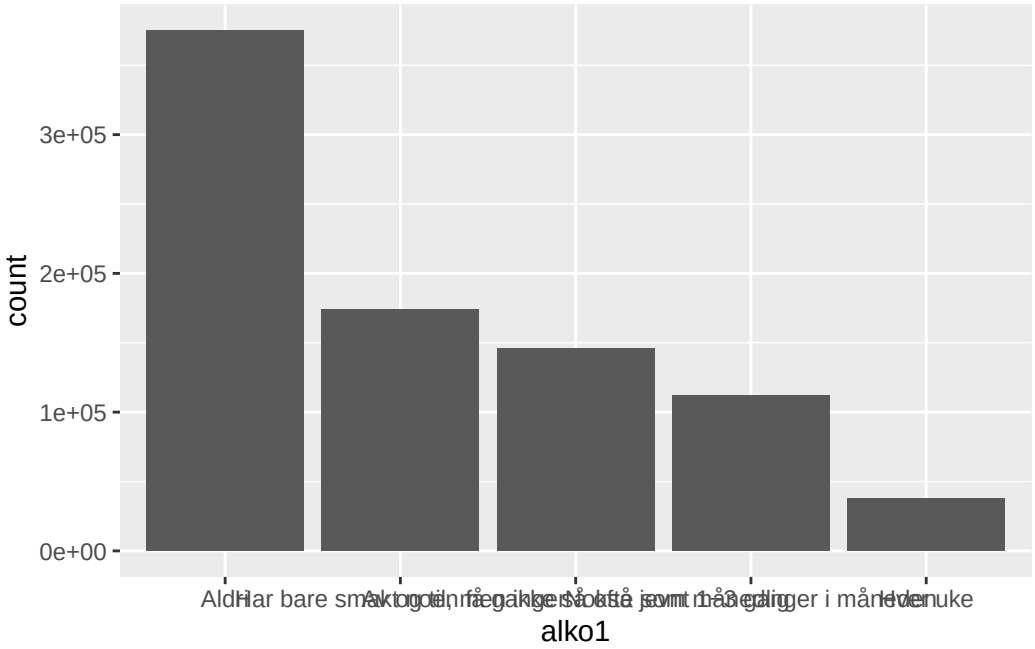


Merk at y-aksen har fått antallene notert i scientific notation. Det er ikke så pent. Det kan vi fikse på med `scale_y_continuous()` som gir oss mulighet til å spesifisere hvordan akseverdiene skal se ut. Pakken {scales} inneholder en rekke funksjoner for å formatere tallverdier. Her bruker vi `number_format` som spesifiserer nøyaktighet til 1, dvs. heltall.

```
ggplot(ungdata_alko, aes(x = alko1)) +
  geom_bar() +
  scale_y_continuous(labels = scales::number_format(accuracy = 1))
```

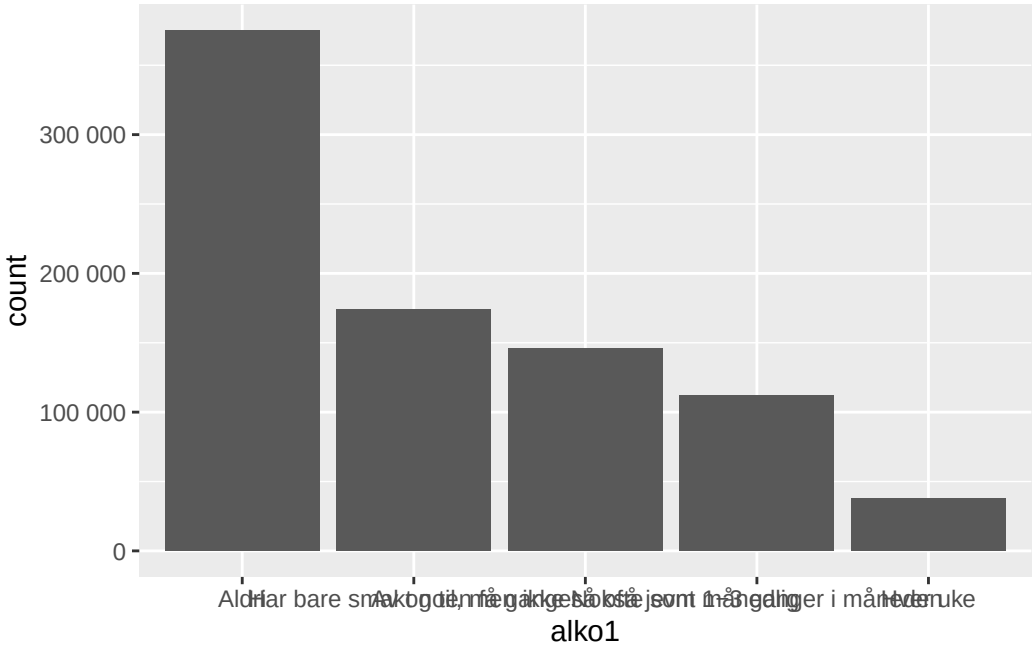


Det er også mulig å spesifisere at det skal være andeler i stedet for antall. I ggplot finnes det noen spesielle funksjoner som starter med `..` deriblant `..prop..` som gir andeler. Men for at det skal regnes ut riktig må vi også spesifisere at det ikke er andelen i hver kategori, men andelen totalt. Det gjøres med `group = 1` som betyr at alle observasjonene skal grupperes sammen. For å få prosent i stedet for desimaltall ganger vi med 100.

```
ggplot(ungdata_alko, aes(x = alko1, y = ..prop..*100, group = 1)) +
  geom_bar()
```

```
Warning: The dot-dot notation (`..prop..`) was deprecated in ggplot2 3.4.0.
i Please use `after_stat(prop)` instead.
```

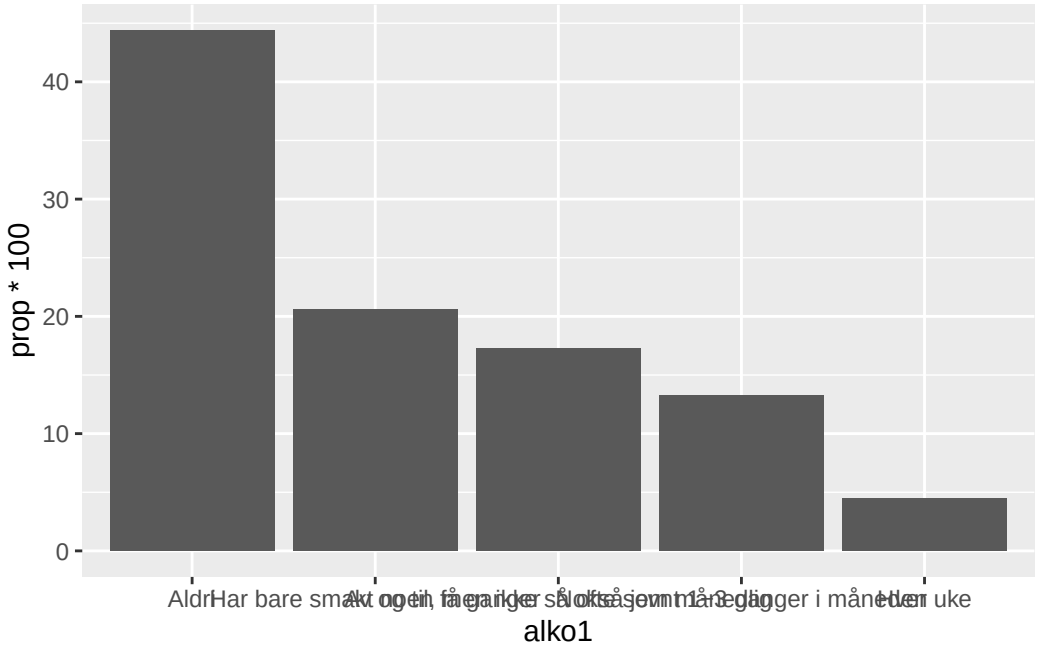


```
# ggplot(ungdata_alko, aes(x = alko1, y = after_stat(prop)*100, group = 1)) +
#   geom_bar()
```

Nå gjenstår det litt ryddejobb og vi gjør disse tingene samtidig. Merk at x-aksen har noen lange tekststrenger som blir uleselige. Det kan vi fikse på med `scale_x_discrete` der vi kan spesifisere label og bruke funksjonen `str_wrap` fra pakken {stringr} som bryter opp tekststrengen etter en gitt bredde. Her har vi satt bredde til 20. Koden er litt komplisert for nybegynnere i R, så det er ikke så farlig om du ikke skjønner alt. Den linjen kan brukes i andre sammenhenger og bare endre `width =` etter behov.

Det neste som trengs er å endre aksetekstene. Det gjøres med `labs()` der vi kan spesifisere x- og y-akse og også tittel og kilde.

```
ggplot(ungdata_alko, aes(x = alko1, y = ..prop..*100, group = 1)) +
  geom_bar() +
  scale_x_discrete(labels = function(x) str_wrap(x, width = 20)) +
  labs(x = "",
       y = "Prosent",
       title = "Antall som drikker alkohol",
       caption = "Kilde: Ungdata 2010-2020")
```


Kilde: Ungdata 2010–2020

## 2.3 Stolpediagram med flere variable

Noen ganger ønsker man å vise fordelingen for to ulike grupper, la oss si for kjønn. En mulighet er da å rett og slett lage to stolpediagram ved siden av hverandre. Til dette kan man spesifisere at dataene er gruppert etter variabelen *kjonn* og at fyllfargen skal settes etter denne variablen med `fill = kjonn`.

Det er også mulig å spesifisere at stolpene skal plasseres ved siden av hverandre i stedet for oppå hverandre. Det gjøres med `position = "dodge"`. [1]

Tegnforklaringen plasseres automatisk til høyre for plottet. Vi kan imidlertid flytte den til bunnen med `theme(legend.position = "bottom")` og fjerne tittelen på tegnforklaringen med `legend.title = element_blank()`.

```
ggplot(ungdata_alko, aes(x = alko1, y = ..prop..*100, group = kjonn, fill = kjonn)) +
  geom_bar(position = "dodge") +
  scale_x_discrete(labels = function(x) str_wrap(x, width = 20)) +
  labs(x = "",
       y = "Prosent",
       title = "Antall som drikker alkohol",
```

[1] Alternativet, som er det automatisk forvalget, er `position = "stack"` hvor stolpene ville blitt plassert oppå hverandre.

```
      caption = "Kilde: Ungdata 2010-2020") +
  theme(legend.position = "bottom", legend.title = element_blank())
```

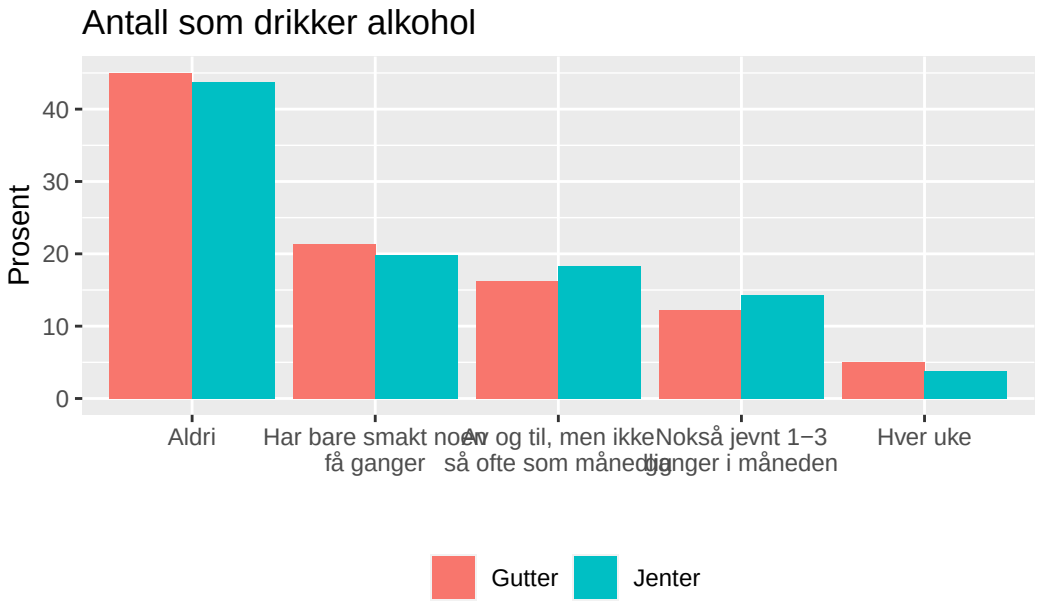


Et alternativ er å plassere grafikken for menn og kvinner ved siden av hverandre. Å legge til `facet_wrap` gjør dette. Da blir det trangere på x-aksen til teksten, så en mulighet er da å snu plottet med `coord_flip`.

```
ggplot(ungdata_alko, aes(x = alko1, y = ..prop..*100, group = 1)) +
  geom_bar() +
  scale_x_discrete(labels = function(x) str_wrap(x, width = 20)) +
  labs(x = "",
       y = "Prosent",
       title = "Antall som drikker alkohol",
       caption = "Kilde: Ungdata 2010-2020") +
  facet_wrap(~kjonn) +
  coord_flip()
```

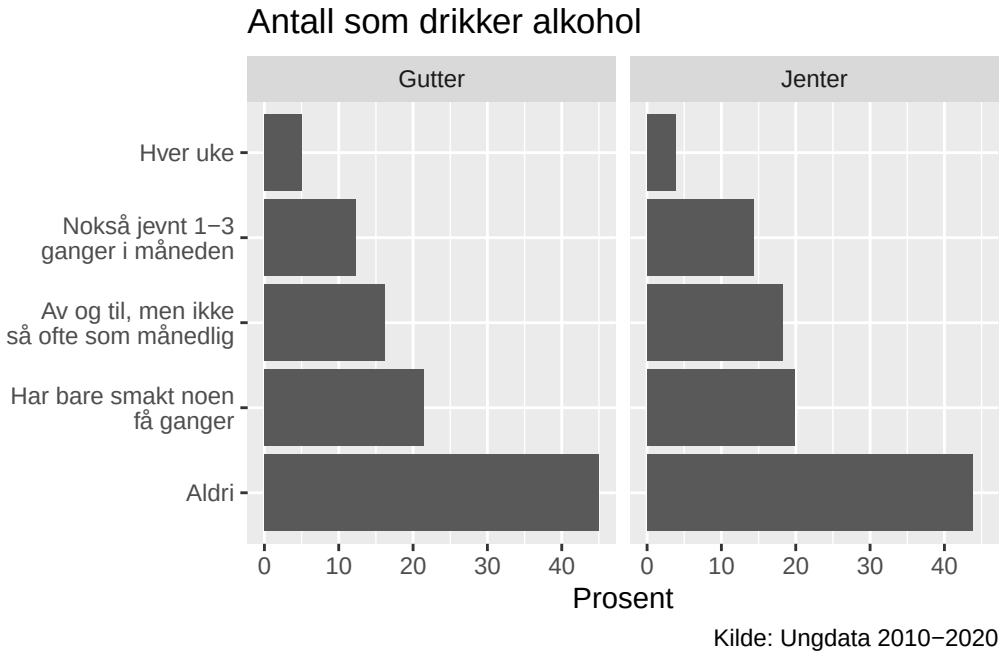


Et automatisk forvalg for `geom_bar()` er hvordan gruppene plasseres som er `position="stack"`. Det betyr at gruppene stables oppå hverandre. Dette er godt egnet hvis poenget er å vise hvor mange av hvert kjønn som er i hver gruppe. Det er mindre egnet hvis du ønsker å sammenligne menn og kvinner. Da er alternativet å velge `position="dodge"` som følger:

### 2.3.1 Kakediagram

Generelt er ikke kakediagram å anbefale da korrekt tolkning involverer å tolke et areal som inneholder vinkel. Det er intuitivt vanskelig å se hvor store hvert kakestykke er med det blotte øyet - med mindre man skriver tallene på,da. Men da kunne man jo også bare laget en tabell?

Med få kategorier som er rimelig forskjellig kan det gi et ok inntrykk, men ofte ender man opp med å måtte skrive på tallene likevel. Vi tar det med her egentlig bare fordi mange insisterer på å bruke det. Så vet du at det er mulig.

Første steg er å lage et aggregert datasett med antall observasjoner og prosent i hver kategori, som vist nedenfor. Dette dekker vi i et senere kapittel og fokuserer på selve plottet her.

```
# A tibble: 5 x 4
  alko1                                    n   pct lab.pos
  <fct>                                <int> <dbl>   <dbl>
```

```
1 Hver uke                                   37576  4.45    2.22
2 Nokså jevnt 1-3 ganger i måneden          112311 13.3    11.1
3 Av og til, men ikke så ofte som månedlig  145934 17.3    26.4
4 Har bare smakt noen få ganger             174322 20.6    45.3
5 Aldri                                     374957 44.4    77.8
```

Utgangspunktet er et stolpediagram som vi har laget ovenfor. Det er bare å bytte ut `geom_bar` med `geom_col` som er en forkortelse for `geom_col(stat = "identity")`. Det betyr at høyden på stolpene er gitt i datasettet. For å lage et kakediagram må vi også legge til `coord_polar` som gjør at det blir sirkulært.

```
ggplot(alko1_sum, aes(x = "", y = pct, fill = alko1)) +
  geom_col() +
  coord_polar("y", start=0)
```

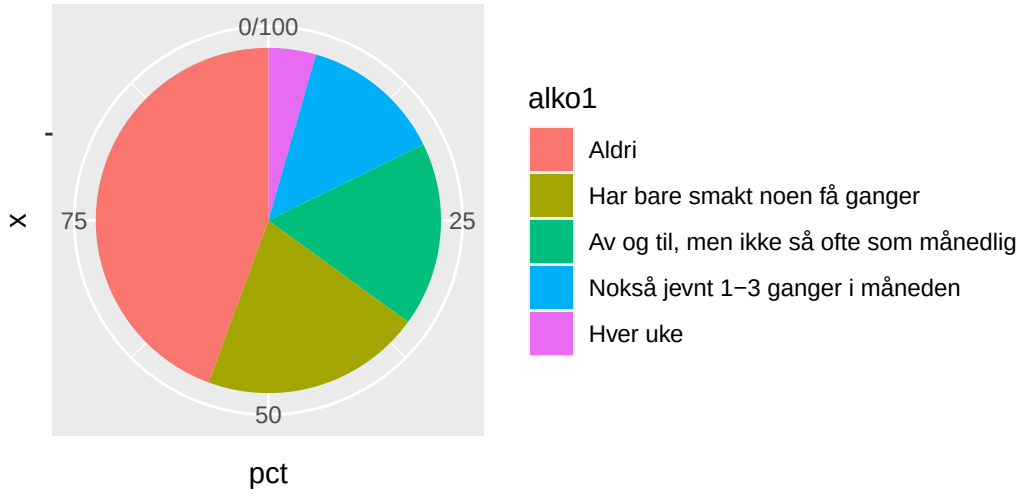


For å gjøre plottet penere fjerner vi hjelpelinjene, legger til prosenttallene innenfor kakestykkene og endrer fargepaletten.

```
ggplot(alko1_sum, aes(x = "", y = pct, fill = alko1)) +
  geom_col() +
  coord_polar("y", start=0) +
```

```
  theme_void()+
  geom_text(aes(y = lab.pos, x=1.6, label = paste(round(pct), "%" )))+
  scale_fill_brewer(palette="Blues", direction = -1)
```

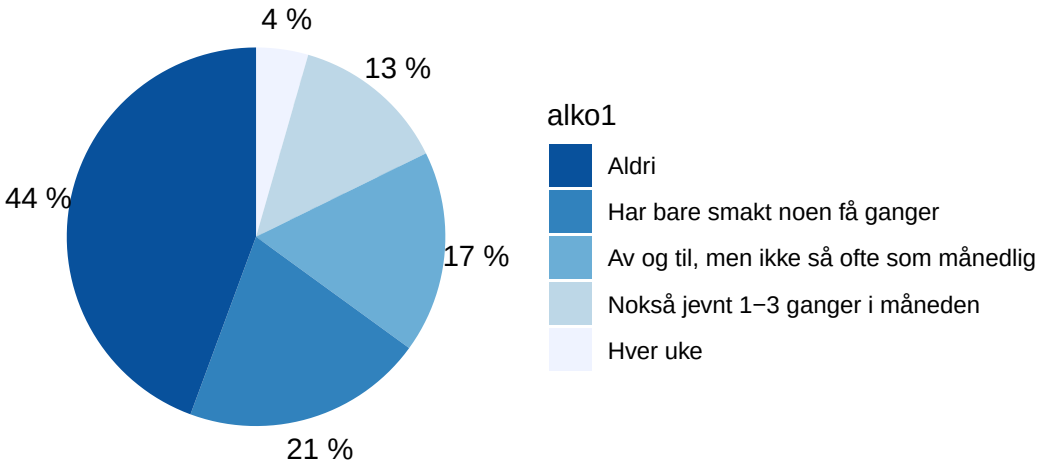


Det er også mulig å lage et kakediagram for hver gruppe. Da må vi legge til `facet_wrap` som vi har brukt tidligere. Det forutsetter at dataene er tilsvarende laget for hver gruppe. Objektet *alko1_sum2* har aggregert data for kjønn.

```
# A tibble: 10 x 5
   alko1                                kjonn       n   pct lab.pos
   <fct>                                <fct>   <int> <dbl>   <dbl>
 1 Hver uke                             Jenter  16528  3.86    1.93
 2 Hver uke                             Gutter  21048  5.05    2.53
 3 Nokså jevnt 1-3 ganger i måneden      Gutter  51195 12.3    11.2
 4 Nokså jevnt 1-3 ganger i måneden      Jenter  61116 14.3    11.0
 5 Av og til, men ikke så ofte som månedlig Gutter  67666 16.2    25.5
 6 Av og til, men ikke så ofte som månedlig Jenter  78268 18.3    27.3
 7 Har bare smakt noen få ganger        Jenter  85078 19.9    46.3
 8 Har bare smakt noen få ganger        Gutter  89244 21.4    44.3
 9 Aldri                                Jenter 187380 43.7    78.1
10 Aldri                                Gutter 187577 45.0    77.5
```

```
ggplot(alko1_sum2, aes(x = "", y = pct, fill = alko1)) +
  geom_col() +
  coord_polar("y", start=0) +
  theme_void()+
  geom_text(aes(y = lab.pos, x=1.6, label = paste(round(pct), "%" )))+
  scale_fill_brewer(palette="Blues", direction = -1) +
  facet_wrap(~kjonn)
```

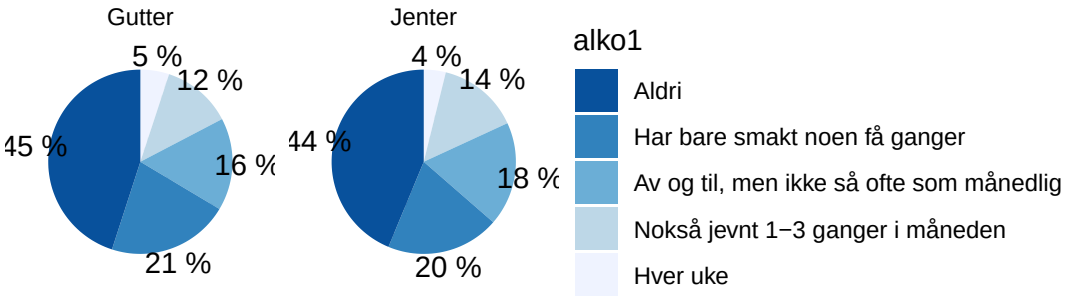


## 2.4 Grafikk for kontinuerlige data

Vi skal nå se på hvordan vi kan fremstille kontinuerlige data. Vi bruker et annet uttrekk fra Ungdata der en rekke spørsmål er aggregert til en indeks for livskvalitet og en indeks for atferdsproblemer. Indeksene er laget ved å ta gjennomsnittet av de enkelte spørsmålene, og konstruert slik at høyere verdier betyr bedre livskvalitet og færre atferdsproblemer.

### 2.4.1 Histogram

Histogram er en vanlig måte å fremstille kontinuerlige data på. Det er en måte å gruppere dataene i intervaller og høyden på stolpene representerer antall observasjoner i hvert intervall. Alternativt kan stolpene representere *andelen* i hvert intervall eller *tettheten*.

Vi starter med å lage et histogram for livskvalitet. Det gjøres med `geom_histogram`.

```
ggplot(ungdata_kont, aes(x = livskval)) +
  geom_histogram()
```

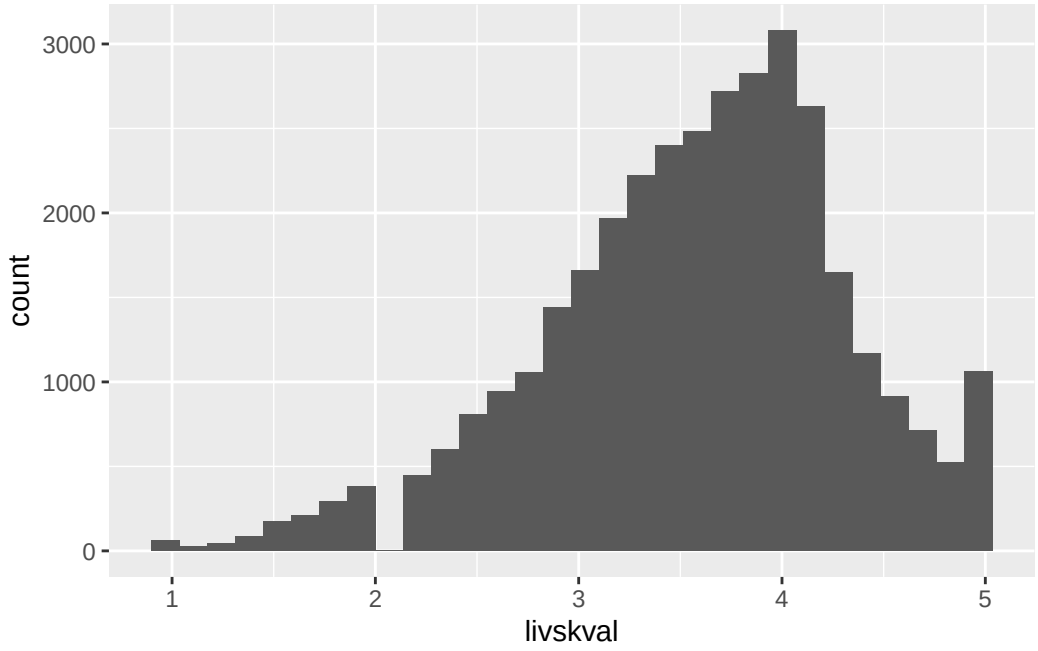


Antall og bredden på intervallene bestemmes automatisk av R. Det er ikke alltid optimale valg, og det kan være greit å justere dette selv. Det gjøres med `binwidth` som angir bredden på intervallene. I eksempelet over ser fordelingen litt pussig ut med et tomt intervall, men det kan skyldes hvordan intervallene tilfeldigvis ble plassert. Hvis plottet ser pussig ut bør man sjekke om det er fordi intervallene er for brede eller smale. Følgende kode gjør en liten endring, og du kan selv sjekke med ulike verdier for `binwidth` og se hvordand et påvirker resultatet.

```
ggplot(ungdata_kont, aes(x = livskval)) +
  geom_histogram(binwidth = .15)
```

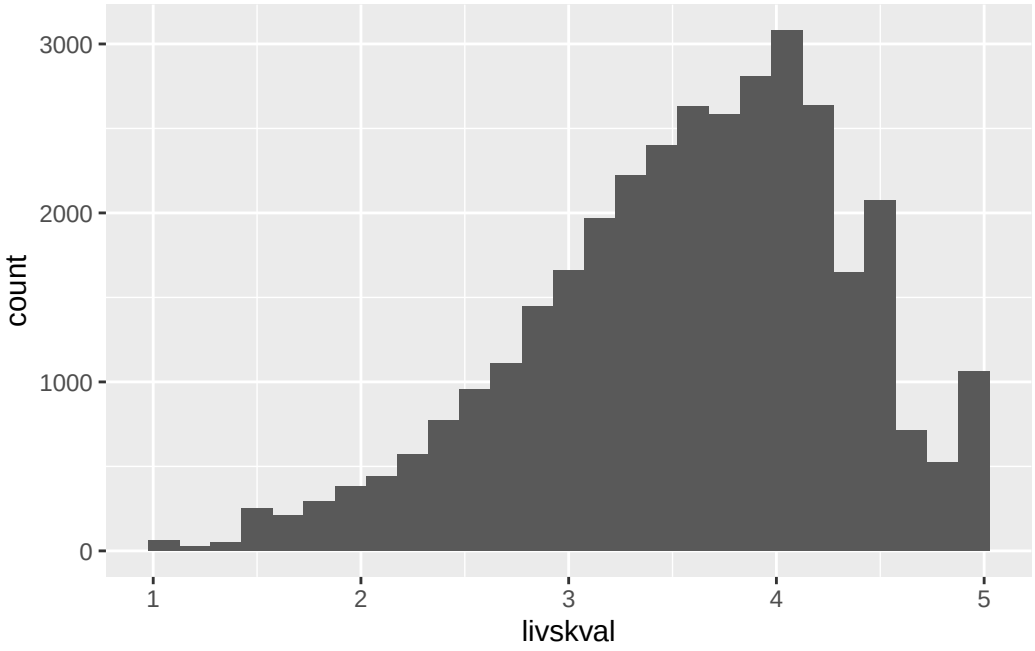


Det er også vanlig å fremstille det samme på en "tetthetsskala", der arealet summeres til 1. Det betyr at arealet for hvert intervall tilsvarer en andel. Visuelt sett er det vel så mye arealet vi oppfatter som høyden på stolpene. Men det er bare skalaen på y-aksen som har endret seg. Visuelt sett, ser histogrammene helt like ut.

```
ggplot(ungdata_kont, aes(x = livskval, y = ..density..)) +
  geom_histogram(binwidth = .15)
```

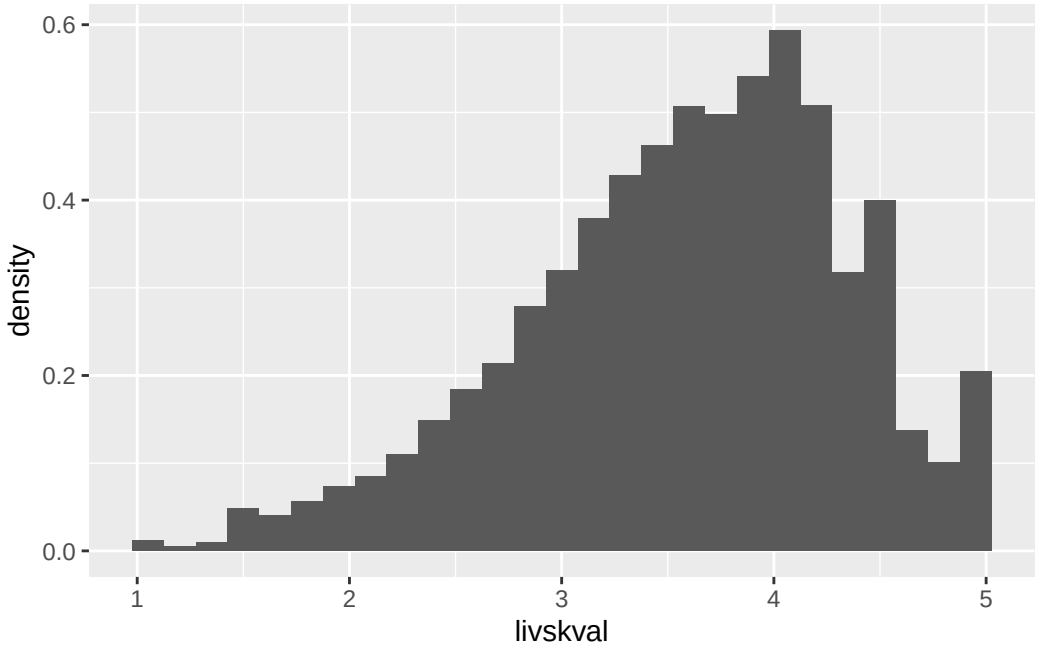


### 2.4.2 Density plot

Density plot er en måte å fremstille det samme på, men i stedet for å dele inn i intervaller som i histogram lager vi en glattet kurve. Det blir på skalaen "tetthet" som i histogrammet ovenfor. På tilsvarende måte som `binwidth` kan vi justere hvor glatt kurven skal være med `bw` som står for *bandwidth*. Høyere tall gir mer glattet kurve, mens lavere tall gir mer detaljert kurve. Vanligvis vil det automatiske forvalget som R gjør for deg være bra nok, men det kan også være aktuelt å justere dette selv som vist nedenfor.

```
ggplot(ungdata_kont, aes(x = livskval)) +
  geom_density(bw = .1)
```

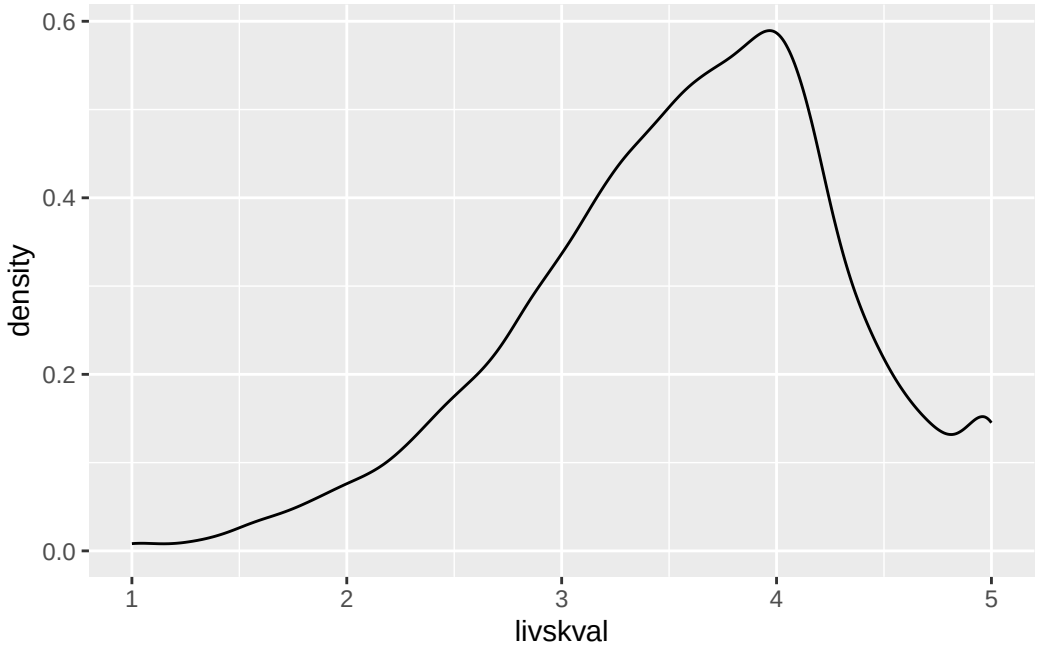


Vi kan legge et histogram og density plot oppå hverandre da y-skalen er lik. Da ser man lettere at det er samme informasjon som fremstilles på ulike måter.

```
ggplot(ungdata_kont, aes(x = livskval)) +
  geom_histogram(aes(y = ..density..), binwidth = .15,  fill = "lightgrey", col = "grey") +
  geom_density(col = "red", linewidth = 1, bw = .1) +
  theme_minimal()
```

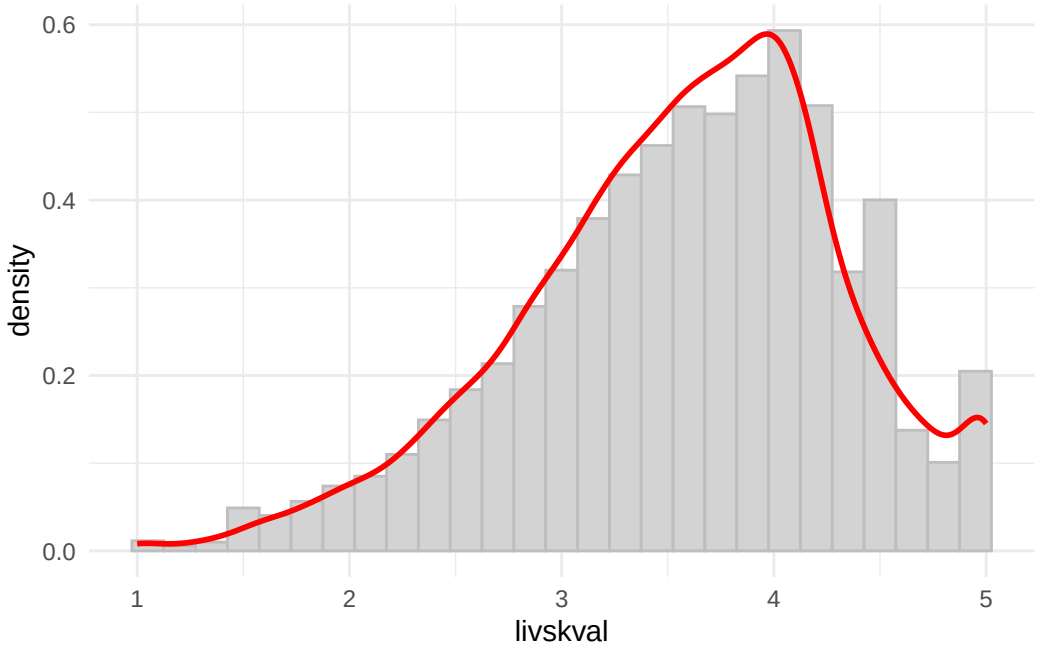


En fordel med tetthetsplot er at det er lettere å sammenligne grupper. Her er et eksempel som viser fordelingen av livskvalitet etter kjønn. Vi ser at gutter gjennomgående rapporterer høyere livskvalitet enn jenter. Begge kurvene er skjeve med en lang hale til venstre, men kurven for gutter er skjevere enn for jenter.

```
ggplot(ungdata_kont, aes(x = livskval, group = kjonn, color = kjonn)) +
  geom_density(linewidth = 1, bw = .1)+
  guides(fill = guide_legend(override.aes = list(shape = 1 ) ) ) +
  theme_minimal()
```

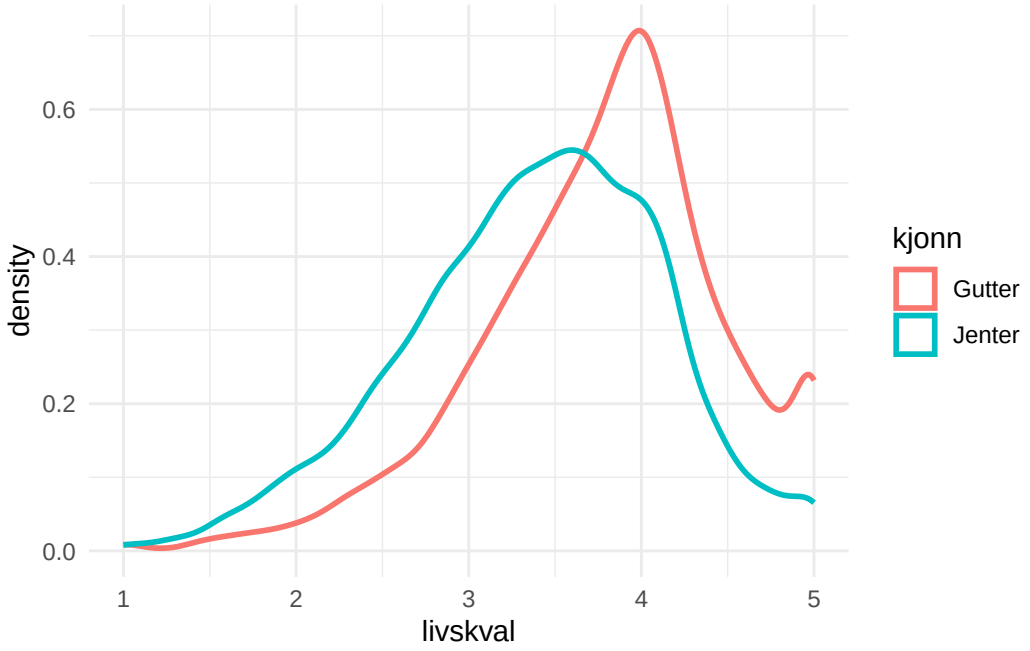


Vi har tidligere vist bruken av `facet_wrap` for å lage flere plott ved siden av hverandre. Det kan også brukes her. Da må vi legge til `facet_wrap(~kjonn)` som betyr at vi vil ha to plott, ett for hver verdi av kjønn. Hvilken fremstilling som er best i et gitt tilfelle kommer an på hva man ønsker fremheve og hva som er mest informativt. Generelt sett er det å legge plottene oppå hverandre best når man ønsker gjøre en direkte sammenligning, mens ved siden av hverandre hvis man ønsker å se på hver gruppe for seg.

```
ggplot(ungdata_kont, aes(x = livskval)) +
  geom_density(linewidth = 1, bw = .1)+
  theme_minimal()+
  facet_wrap(~kjonn)
```

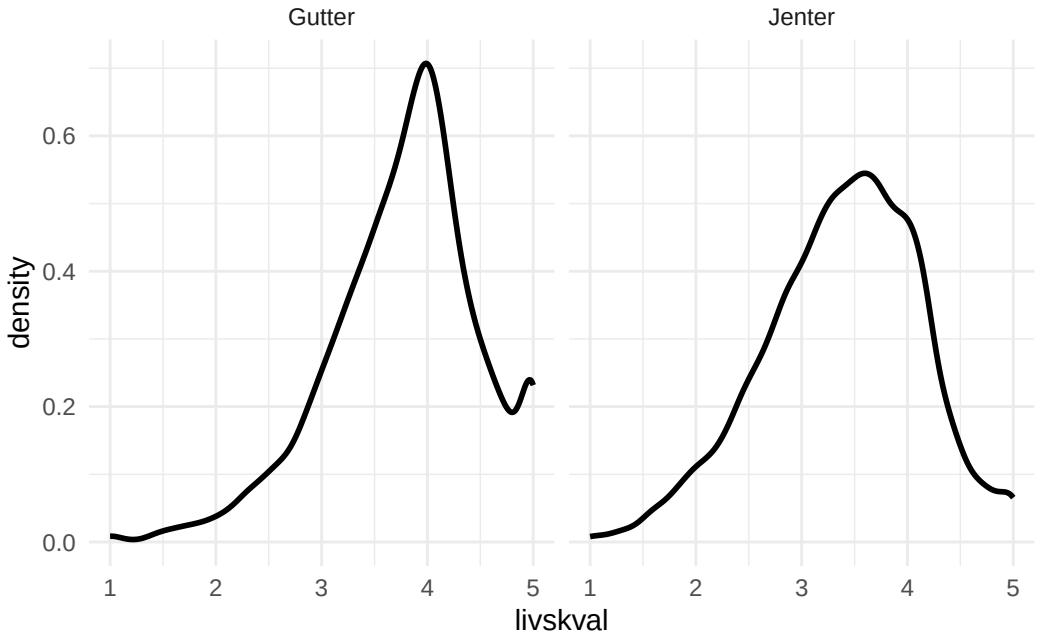


En variant av samme fremstilling er å bruke fyllfarge i stedet for linjefarge. Da må vi legge til `fill = kjonn` i `aes()`. Det er også mulig å endre tittel på tegnforklaring fra variabelnavnet til noe mer gramatisk korrekt med `guides(fill=guide_legend(title="Kjønn"))`.

```
ggplot(ungdata_kont, aes(x = livskval, group = kjonn,  fill = kjonn)) +
  geom_density(alpha = .3, bw = .1)+
  guides(fill=guide_legend(title="Kjønn"))+
  theme_minimal()
```

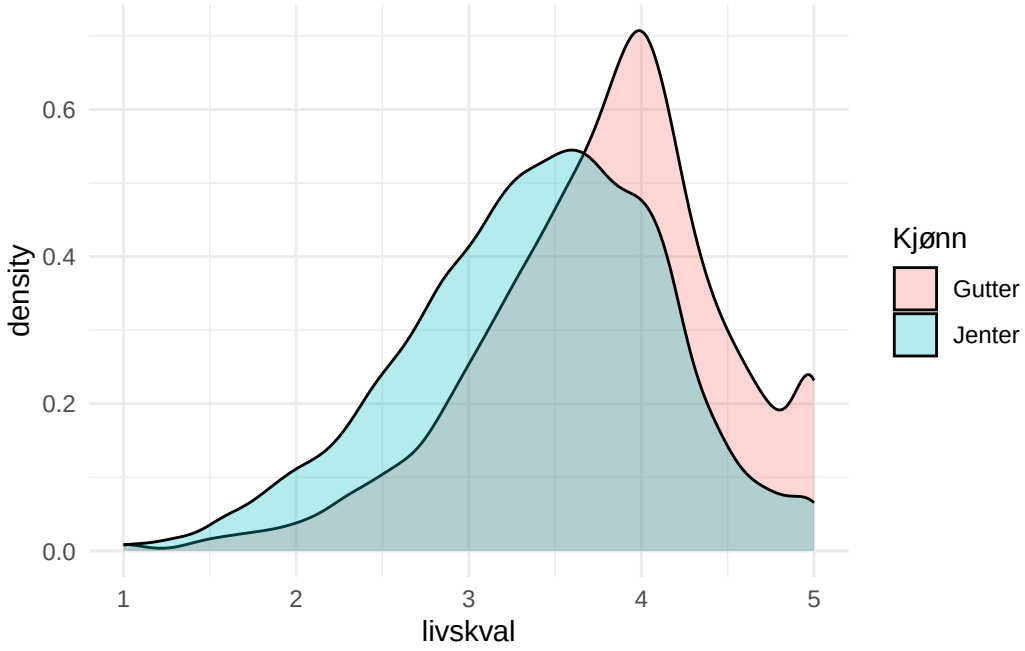


### 2.4.3 Flere variable samtidig

#### 2.4.3.1 Boksplot

```
ggplot(ungdata_kont, aes(y = livskval, group = kjonn)) +
  geom_boxplot()+
  theme_minimal()
```

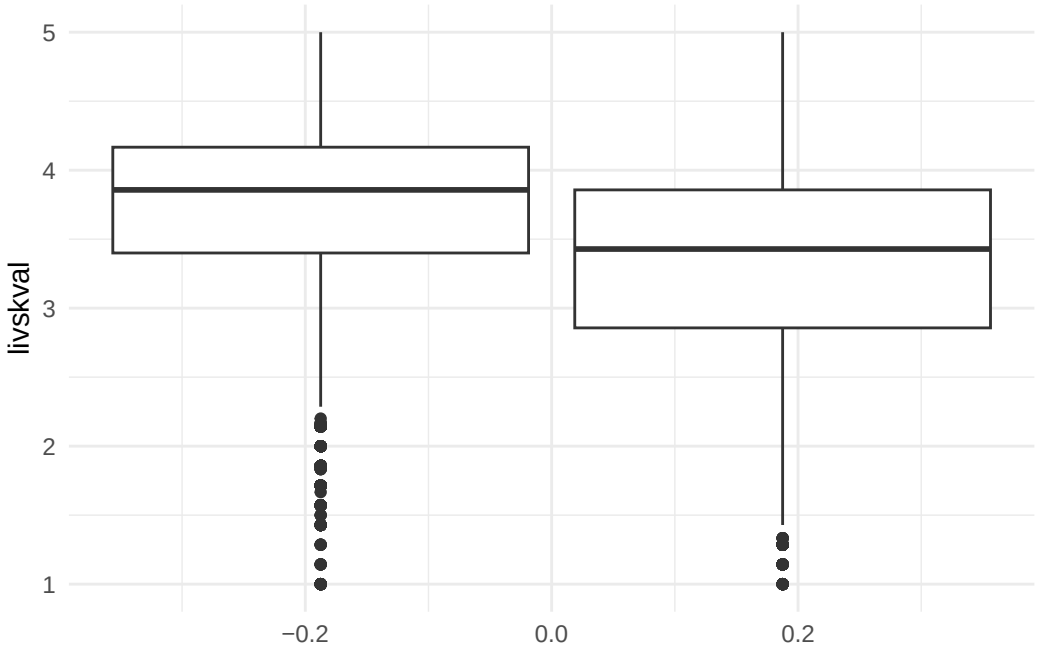


#### 2.4.3.2 Ridgeplot

Ridgeplot er en annen måte å sammenligne en kontinuerlig fordeling betinget på en gruppering.

```
library(ggridges)
ggplot( ungdata_kont, aes(x = livskval, y = klasse)) +
  geom_density_ridges()
```

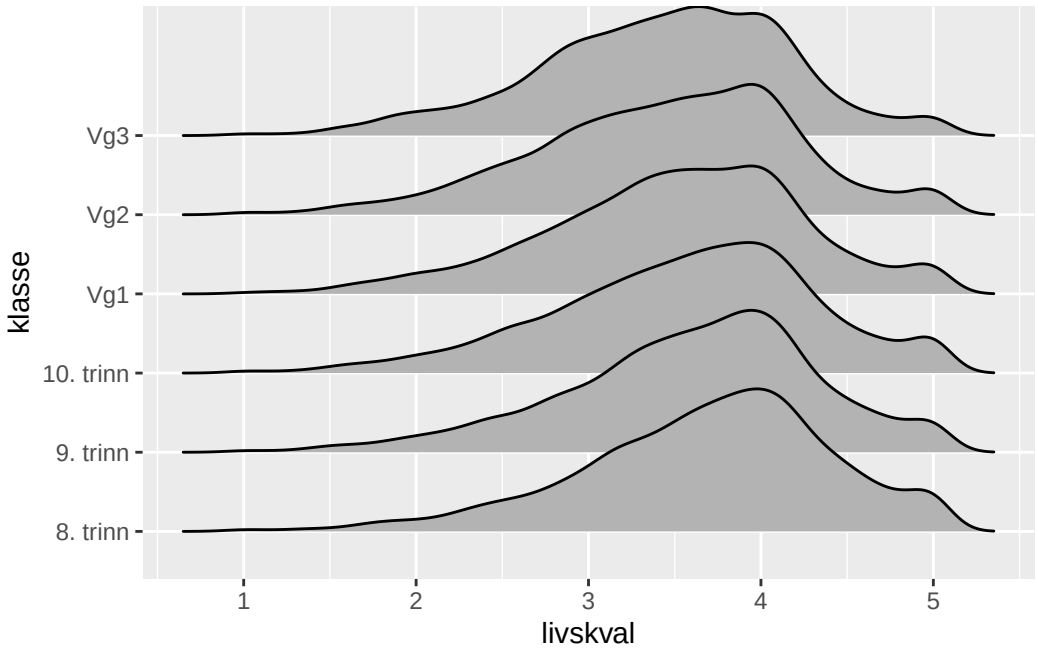


#### 2.4.3.3 Scatterplot

```
ggplot(ungdata_kont, aes(x = livskval, y = samfunnstillit)) +
  geom_point()+
  theme_minimal()
```

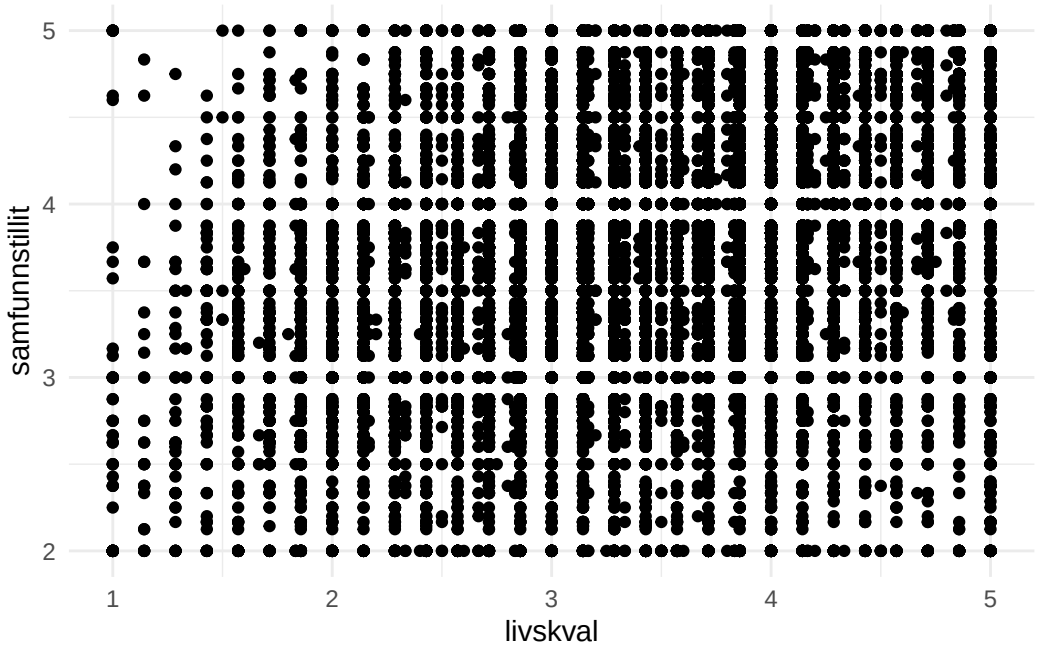


Når det er mange observasjoner kan det bli litt rotete med punkter som overlapper hverandre. Det er vanskelig å se noen mønstre i et slikt plot. Det kan bedres med noen teknikker for å fremheve nettopp hvor de fleste datapunktene er. I det følgende gjør vi to ting samtidig: legger til gjennomsiktig farge på punktene med `alpha =` som angir grad av gjennomsiktighet. Når alpha er 1 er det ingen gjennomsiktighet, og ved 0 er det helt gjennomsiktig. Her må man prøve seg frem. I tillegg bruker vi `geom_jitter` som legger til litt tilfeldig støy på hvert datapunkt slik at de ikke så ofte ligger akkurat oppå hverandre.

Her har vi valgt en veldig høy grad av gjennomsiktighet slik at relativt vanlige verdier synes tydelig, mens mer sjeldne verdier blir nesten usynlige.

```
ggplot(ungdata_kont, aes(x = livskval, y = samfunnstillit)) +
  geom_jitter(alpha=.05)+
  theme_minimal()
```

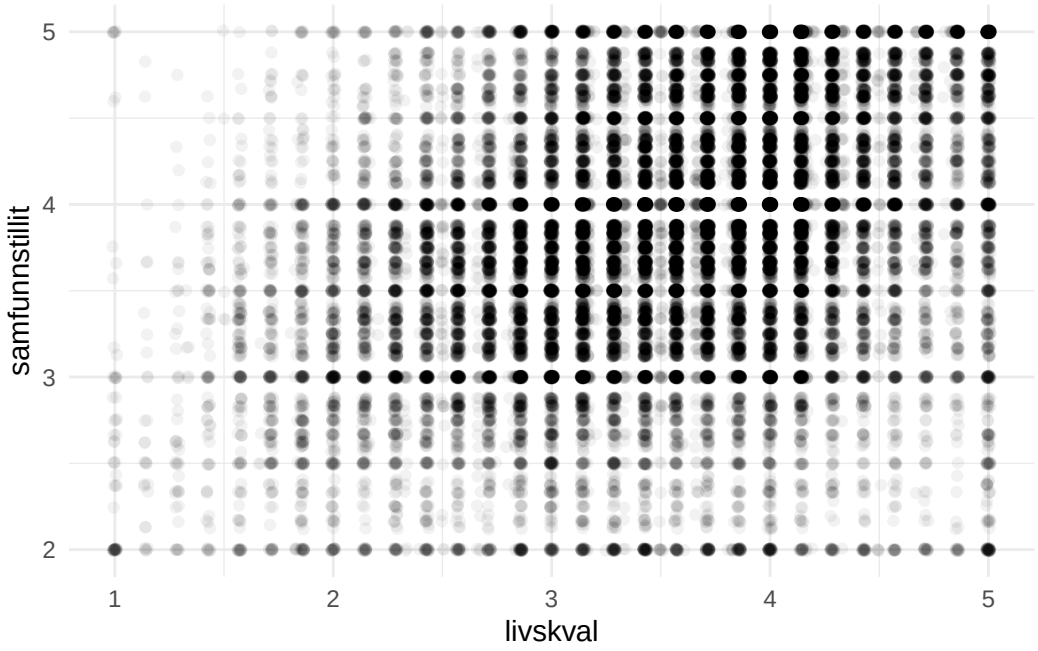


```
ggplot(ungdata_kont, aes(x = livskval, y = samfunnstillit)) +
  geom_hex(bins = 10)+
  theme_minimal()
```

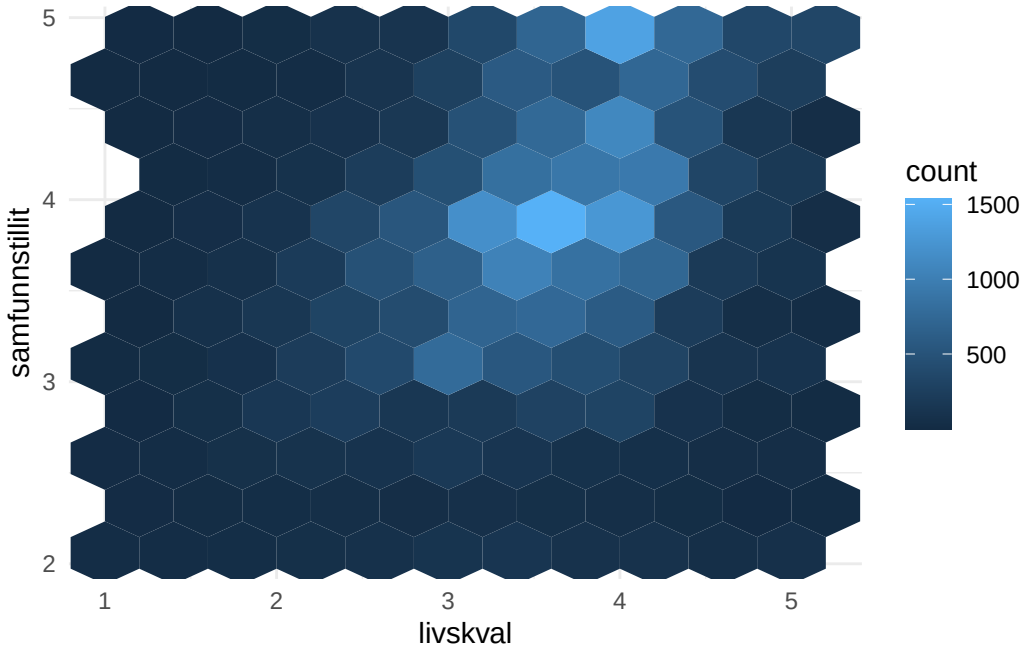


Det er også mulig å legge til en glattet kurve som viser tettheten av punktene. Det gjøres med `geom_density_2d_filled` som lager et konturplot der arealet under kurven er fargekodet. Det er også mulig å legge til konturlinjer med `geom_density_2d`. Nedenfor er begge brukt samtidig, men man kan også velge bare en av dem.

```
ggplot(ungdata_kont, aes(x = livskval, y = samfunnstillit)) +
  geom_density_2d_filled()+
  geom_density_2d(col = "white")+
  theme_minimal()
```

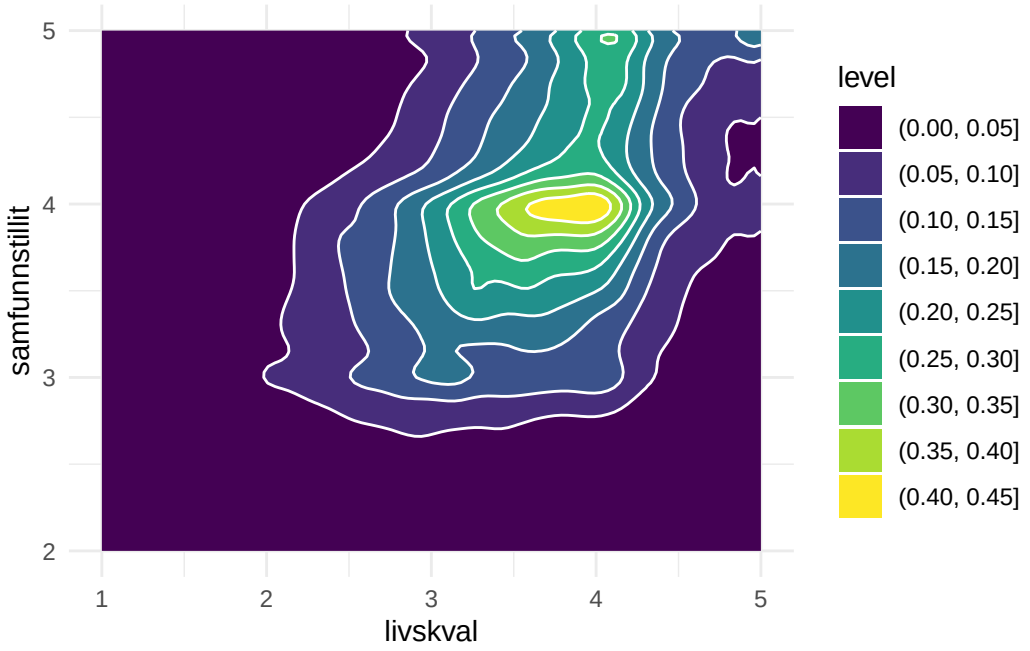


NOVA, and Anders Bakken. 2023. "Ungdata 2010-2023." https://doi.org/10.18712/NSD-NSD3157-V1; Sikt.